RELATÓRIO EXECUTIVO & METODOLÓGICO

Sentimento de Redes Sociais, Ironia e Manipulação na B3

Case Trainee CF Tech · Tema 06 | **Autores:** João Pedro & Equipe Quant | **Data:** Nov/2026 | **Tag:** v1.0

1. Resumo Executivo e Síntese de Decisão

Este estudo investiga empiricamente a viabilidade de extrair sinal preditivo a partir de postagens de redes sociais no mercado de capitais brasileiro (B3), com ênfase no tratamento de sarcasmo/ironia, detecção de manipulação coordenada e rigor metodológico para evitar descobertas espúrias.

Síntese dos Resultados Chave:
• ***Ganho Expressivo com Engenharia de Prompt:*** *O modelo Google Gemini Flash Lite atingiu* ***Kappa de Cohen de 0,615*** *e 75,0% de acurácia no Prompt v2. A acurácia em* ***posts irônicos subiu de 60,0% para 70,0%*** *(+10 p.p.) com diretrizes semânticas customizadas.*
• ***Economia Estrutural via TOON Tabular:*** *Redução de 34% no consumo de tokens frente ao JSON, com custo total de apenas* ***US$ 0,0013*** *para 100 posts e 100% de taxa de validação sintática via Pydantic.*
• ***Coordenação de Redes vs. Ruído Orgânico:*** *90% dos clusters detectados por rajada algorítmica revelaram-se falso positivos (orgânicos) na auditoria humana, atestando a ineficácia de filtros cegos sem intervenção qualitativa.*
• ***Ausência de Alfa Preditivo em Painel:*** *Controlando por retornos passados e aplicando a correção de* ***Holm-Bonferroni****, o sentimento não previu os retornos em excesso do Ibovespa (t = -0,65, p_adj = 1,00). O teste placebo comprovou reatividade a perdas passadas (t = -2,39, p = 0,0167), demonstrando que o varejo reage tardiamente às oscilações de preço.*

2. Engenharia de Dados, Limpeza e Desambiguação

A base real analisada reúne 100 postagens de investidores da B3 coletadas em redes abertas (Investing.com, Reddit, Instagram). O pré-processamento aplicou critérios estritos para integridade da série temporal:

- **Alinhamento de Fuso Horário:** Conversão de todos os registros para o fuso local America/Sao_Paulo, garantindo sincronização exata com os horários de negociação.
- **Horário de Corte Dinâmico (17h/18h):** O encerramento da B3 oscila sazonalmente conforme o horário de verão dos EUA (DST). O pipeline consulta o calendário da B3 atribuindo postagens pós-fechamento ao pregão seguinte sem lookahead bias.
- **Normalização de Tickers e Stoplist:** Expressões em minúsculas (petr4) e lotes fracionários (PETR4F) foram unificados ao ativo base. Termos de 4 letras + dígito que não representam ações (COVID19, WIN10) foram descartados.
- **Filtro de Desambiguação ('Vale'):** Expressões lexicais verbais frequentes como *'vale a pena comprar'* ou *'não vale nada'* foram neutralizadas via regex previamente à extração para evitar falsos positivos na mineradora Vale S.A. (VALE3).
- **Distribuição dos Ativos:** 12 ativos mapeados, com concentração maciça em estatais federais: **BBAS3** (42 posts), **PETR4** (40 posts) e **CMIG4** (10 posts). 7 posts representavam conjuntura macroeconômica sem ativo específico.

3. Protocolo de Rotulagem Humana & Consenso (Ground Truth)

Para garantir rigor científico e total ausência de contaminação por LLMs, o gabarito humano foi produzido de forma independente pela dupla antes de qualquer interação com a API:

- **Rotulagem Cega Independente:** Anotador A e Anotador B classificaram os 100 posts isoladamente, produzindo rotulos_A.csv e rotulos_B.csv.
- **Métricas de Concordância Humana:** Acurácia entre anotadores de **88,0%**, gerando **Kappa de Cohen de 0,811** e **Kappa ponderado de 0,845** (concordância quase perfeita). O Kappa para detecção de ironia atingiu **0,968** (99% de concordância

bruta).

- **Sessão de Consenso:** As 31 divergências de sentimento e flags foram deliberadas em sessão conjunta, documentadas em decisoes_consenso.csv e consolidadas em rotulos_consenso.csv (44 neutros, 36 positivos, 20 negativos).

4. Classificação por LLM: Prompts, Ironia e Diagnóstico de Erros

Utilizou-se o modelo **Google Gemini Flash Lite** com **temperatura 0 estrita** e validação estrutural via Pydantic. A tabela abaixo compara o desempenho do Prompt v1 contra o Prompt v2 na amostra de avaliação:

Versão	Modelo	N	Kappa	Kappa P.	Acurácia	F1-Macro	Sem Ironia (80)	Com Ironia (20)	Custo USD
v1	Gemini Flash Lite	100	0.593	0.634	73.0%	0.732	76.2%	60.0%	$0.00108
v2	Gemini Flash Lite	100	**0.615**	**0.620**	**75.0%**	**0.749**	76.2%	**70.0%**	$0.00133

Evolução Metodológica e Tratamento de Ironia no Prompt v2:

A evolução de v1 para v2 representou um ganho qualitativo crucial no tratamento do sarcasmo financeiro. No prompt v1, postagens com forte ironia (ex: *'Parabéns aos envolvidos, MGLU3 derretendo mais 6% hoje* ■*'*) eram categorizadas erroneamente como 'positivo' devido à análise estritamente léxica de termos elogiosos isolados. O Prompt v2 introduziu **regras de inversão contextual de polaridade**, dicionário de jargões locais (*'foguete não tem ré'*, *'segurar a faca caindo'*) e detecção de emojis incongruentes. O resultado foi uma **elevação de 10 pontos percentuais na acurácia sobre posts irônicos (de 60% para 70%)**, elevando o Kappa global de 0,593 para 0,615 (faixa de concordância substancial).

Matriz de Confusão — Humano (Linhas) × LLM v2 (Colunas):

Gabarito \ LLM	Negativo (Previsto)	Neutro (Previsto)	Positivo (Previsto)	Total Real	Acurácia da Classe
Negativo	**15**	4	1	20	75.0%
Neutro	3	**32**	9	44	72.7%
Positivo	0	8	**28**	36	77.8%

Catálogo de Erros e Padrões de Falha do Modelo:

- **Realização de Lucros vs. Pessimismo:** Posts onde investidores comemoravam lucros elevados e anunciavam saída da posição (*'PM R$30, vendi tudo a R$50 e botei no bolso'*) foram classificados pelo LLM como neutros/positivos, desconsiderando que desinvestimentos representam pressão vendedora no pregão.
- **Notícias Neutras com Fatos Negativos:** Compartilhamento estrito de notícias (ex: *'Banco tem pane de sistemas e cotação pode recuar'*) sem adjetivação pessoal do autor foi por vezes interpretado como sentimento negativo próprio.
- **Erros de Alta Confiança:** Dentre os erros com confiança declarada $\ge 0,80$, identificou-se que o modelo é propenso a superestimar sua certeza quando o vocabulário utiliza termos enfáticos de convicção mesmo diante de ironia velada.

5. Detecção de Coordenação e Manipulação de Mercado

O pipeline combina similaridade textual TF-IDF de n-gramas de caracteres com algoritmos de agrupamento por rajada temporal (burst detection) dentro de janelas de 10 minutos. Foram pontuados e revisados os 10 clusters mais suspeitos:

- **Auditoria Humana de Clusters:** Dos 10 clusters revisados, **9 foram classificados como falso positivo (orgânico)** e 1 cluster classificado como **provavelmente coordenado** (Cluster C0002 em CMIG4, onde comentários no Instagram direcionavam usuários com urgência para recomendação de compra na plataforma AGF).
- **Métricas de Precisão do Detector:** Precisão estrita de **0,0%** e precisão lata de **10,0%**.
- **Lição Metodológica Fundamental:** Em redes sociais financeiras, choques de preço externos e eventos corporativos de alta relevância (ex: queda súbita de 7% no barril de petróleo) desencadeiam naturalmente dezenas de mensagens simultâneas com vocabulário altamente correlacionado (*'comprei na queda'*, *'Black Friday de PETR4'*). Modelos puramente quantitativos de rajada sofrem de severa contaminação por falsos positivos se não passarem por triagem qualitativa.

6. Teste Preditivo de Mercado e Econometria em Painel

A questão central para a mesa quantitativa é determinar se o sentimento apurado possui capacidade preditiva sobre a precificação futura dos ativos. Estimou-se uma regressão em painel com a seguinte especificação formal:

Modelo Econométrico:

$$R_{i,\,t+1}^{excesso} = \alpha + \beta \cdot IndiceSentimento_{i,\,t} + \gamma \cdot R_{i,\,t}^{excesso} + \delta \cdot R_{i,\,t-1}^{excesso} + \theta \cdot ln(VolumePosts_{i,\,t}) + \varepsilon_{i,\,t+1}$$

Onde $R_{i,\,t}^{excesso} = R_{ativo,\,i,\,t} - R_{Ibov,\,t}$. Todos os modelos utilizam matriz de covariância robusta a heteroscedasticidade e autocorrelação (**HAC / Newey-West**) e correção de múltiplos testes de **Holm-Bonferroni**.

Versão / Modelo	Variável Dependente (DV)	Coef. (β)	Erro-Padrão (HAC)	Estat. t	p-valor Bruto	p-valor Holm	N (Obs / Tickers)	R^2
llm_bruto (v1)	ret_excesso_f1 (t+1)	-0.0155	0.0174	-0.89	0.3741	1.000	31 (11)	0.076
llm_corrigido (v2)	ret_excesso_f1 (t+1)	-0.0076	0.0117	-0.65	0.5171	1.000	31 (11)	0.045
sem_coordenados	ret_excesso_f1 (t+1)	-0.0079	0.0119	-0.66	0.5100	1.000	30 (11)	0.046
Acumulado 5d (v2)	ret_excesso_acum (t+1:t+5)	+0.0105	0.0323	+0.32	0.7456	1.000	12 (7)	0.394
Volume Anormal (v2)	vol_anormal_f1 (t+1)	+0.0987	0.2549	+0.39	0.6987	1.000	29 (10)	0.249
Placebo Passado (v1)	ret_excesso_lag1 (t-1)	**-0.0123**	0.0051	**-2.39**	**0.0167***	—	31 (11)	0.092
Placebo Passado (v2)	ret_excesso_lag1 (t-1)	+0.0012	0.0059	+0.20	0.8404	—	31 (11)	0.012

Interpretação e Diagnóstico Econométrico:

1. **Inexistência de Alfa Direcional Forward-Looking:** O coeficiente de sentimento nas regressões controladas para o retorno em excesso no pregão seguinte ($t+1$) resultou negativo e não significativo (β = -0,0076; p_bruto = 0,5171; p_holm = 1,000). A mesma insignificância se repete para retornos acumulados em 5 dias (β = +0,0105; p_holm = 1,000) e para volume anormal de negociação.

2. **Revelação do Teste Placebo:** O teste placebo sobre retornos passados (R_{t-1}) no modelo bruto foi altamente significativo (β = -0,0123; t = -2,39; p = 0,0167). Isso comprova a ocorrência de **causalidade reversa**: os investidores pessoas físicas em redes sociais não antecipam oscilações de preço; eles reagem aos choques negativos já ocorridos, transformando o sentimento agregado em um eco defasado do mercado.

3. **Impacto da Exclusão de Coordenação:** A retirada do cluster suspeito (modelo sem_coordenados) manteve a estabilidade dos parâmetros (β = -0,0079 vs -0,0076), atestando que a ausência de sinal preditivo decorre da natureza do ruído de varejo e não de distorções induzidas por campanhas orquestradas.

7. Preparação para a Defesa Oral: Guia de Perguntas Críticas

Apresentam-se a seguir as respostas fundamentadas para as questões conceituais centrais exigidas pela banca examinadora da CF Tech:

Q1. Por que a arquitetura adotou o formato TOON em detrimento do padrão JSON?

O formato TOON tabular (*Topic-Oriented Object Notation*) elimina a redundância estrutural do JSON ao declarar os nomes das chaves uma única vez no cabeçalho (ex: resultados[N]{id,sentimento,confianca,ironia}:) e transmitir os dados linha a linha separados por vírgula. Essa abordagem reduziu em **34% o consumo de caracteres** na chamada e resposta do LLM, além de acelerar o parsing e diminuir drasticamente o custo financeiro da esteira. Adicionalmente, o número de linhas N explicitamente fixado no cabeçalho permite identificar instantaneamente respostas truncadas antes da desserialização no Pydantic.

Q2. O que exatamente o teste placebo comprova e por que ele é indispensável?

O teste placebo substitui a variável dependente futura (R_{t+1}) pelo retorno passado do ativo (R_{t-1}). Por definição ontológica, o sentimento gerado em t não pode exercer causalidade sobre preços formados no passado. Quando um modelo sem controles acusa correlação com R_{t-1}, o teste comprova que o sinal de sentimento é endógeno e reflete a reação do investidor a perdas pregressas. Ignorar o teste placebo induz pesquisadores ao erro de atribuir poder preditivo a séries que apenas espelham tendências passadas.

Q3. Qual a justificativa estatística para o uso de erros-padrão robustos (HAC / Newey-West)?

Em séries temporais e painéis financeiros, os resíduos violam rotineiramente as premissas de Gauss-Markov devido a heteroscedasticidade e correlação serial intra-ativo ao longo do tempo. Erros-padrão de OLS convencionais subestimam a variância dos estimadores, gerando estatísticas t artificialmente inflacionadas e falsos positivos estatísticos. A matriz de covariância HAC (Newey-West) com defasagens ajustadas garante inferência assintoticamente válida mesmo sob dependência temporal.

Q4. Como a correção pela matriz de confusão pode induzir contaminação (leakage)?

Ajustar as proporções populacionais de sentimento invertendo a matriz de confusão calibrada na amostra de avaliação acarreta dois riscos severos: (i) *Lookahead Bias* se a matriz for estimada em dados de períodos posteriores ao ponto de tomada de decisão; e (ii) *Data Snooping* se as classes reais da base ampla divergirem estruturalmente da amostra amostrada (ex: crises pontuais gerando mais pessimismo). Para fins de modelagem quantitativa rigorosa, deve-se utilizar estritamente o sinal inferido ponto-a-ponto sem calibrações globais retroativas.

8. Conclusões e Recomendações Estratégicas para a Mesa Quant

1. **Inviabilidade de Estratégias Direcionais de Frequência Diária:** Recomenda-se formalmente ao comitê quant não alocar capital em estratégias que apostem na continuidade direcional de preços baseada puramente em sentimento de redes abertas em frequência diária.
2. **Utilidade como Indicador de Risco e Assimetria de Cauda:** O valor prático do pipeline reside no monitoramento de anomalias (picos súbitos de queixas ou rajadas de desconfiança) que possam antecipar eventos de cauda, revisões de rating ou surpresas operacionais antes de relatórios trimestrais.
3. **Expansão para Dados de Alta Frequência (Intradiário):** Sugere-se avaliar a microestrutura em janelas de 15 a 60 minutos após eventos corporativos para verificar se a lentidão na absorção de notícias por investidores pessoas físicas gera janelas exploráveis de liquidez.